

МИНОБРНАУКИ РОССИИ
САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ
ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ
«ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА)
Кафедра МОЭВМ

ОТЧЕТ по лабораторной
работе №4
по дисциплине «Построение и анализ алгоритмов»
Тема: Алгоритм Кнута-Морриса-Пратта

Студент гр. 8382

Черницын П.А.

Преподаватель

Фирсов М.А.

Санкт-Петербург

2020

Цель работы.

Ознакомится с алгоритмом Кнута-Морриса-Пратта для поиска подстроки в строке.

Постановка задачи.

Вариант 2. Оптимизация по памяти: программа должна требовать $O(m)$ памяти, где m – длина образца. Это возможно, если не учитывать память, в которой хранится строка поиска.

Задача 1.

Реализуйте алгоритм КМП и с его помощью для заданных шаблона P ($|P| \leq 15000$) и текста T ($|T| \leq 5000000$) найдите все вхождения P в T .

Вход:

Первая строка – P

Вторая строка – T Выход:

Индексы начал вхождений P в T , разделенных запятой, если P не входит в T , то вывести -1

Задача 2.

Заданы две строки A ($|A| \leq 5000000$) и B ($|B| \leq 5000000$). Определить, является ли A циклическим сдвигом B (это значит, что A и B имеют одинаковую длину и A состоит из суффикса B , склеенного с префиксом B). Например, defabc является циклическим сдвигом abcdef.

Вход:

Первая строка – A

Вторая строка – B

Выход:

Если A является циклическим сдвигом B , индекс начала строки B в A , иначе вывести -1 . Если возможно несколько сдвигов вывести первый индекс.

Алгоритм решения.

Реализована префикс-функция. Для нулевого символа строки значение префикс-функции устанавливается 0. Для каждого i -го символа, кроме нулевого, берется значение $k = \text{prefix}[i-1]$. Проверяется, совпадают ли символы на позициях i и k . Если они совпадают, то для i -го элемента устанавливается значение $k + 1$. Если же они не совпадают, то k устанавливается как значение префикс-функции для $k - 1$ -ого элемента. Для обновленного значения k проверка повторяется. Это продолжается до тех пор, пока либо не будут найдены одинаковые символы на позициях i и k , либо k не станет равным 0. В последнем случае на i -ую позицию префикс-функции будет установлена либо 1, если i -ый символ совпадает с первым, либо 0, если не совпадает.

Для поиска шаблона в строке вычисляется префикс-функция шаблона. Затем для строки, в которой осуществляется поиск шаблона происходит процедура, похожая на вычисление префикс-функции, но с некоторыми отличиями: суффикс берется в строке поиска, а префикс – в строке шаблона. Для строки поиска не имеет смысла хранить значения префикс-функции, поэтому запоминается только последнее вычисленное. Если на каком-то символе значение префикс-функции совпадет с длиной шаблона, значит, найден суффикс, совпадающий с шаблоном. Выводится индекс его начала.

Для определения сдвига используется похожий алгоритм. Для второй строки вычисляется префикс-функция. Алгоритм дважды проходит по первой строке с заикливанием. Если в какой-то момент текущее значение максимальной длины суффикса совпадет с длиной первой строки, значит, вторая

строка является сдвигом первой. Выводится индекс начала вхождения второй строки в первой.

Пусть m – длина строки, для которой вычисляется префикс-функция, n – длина второй строки. В вычислении префикс-функции используются два цикла: внешний цикл `for` длиной m и внутренний цикл. Во внешнем цикле значение k может увеличиться максимум на 1 за итерацию (а может и не увеличиваться). Во внутреннем цикле оно уменьшается как минимум на 1 за итерацию, но не может опуститься ниже 0. То есть, каждый заход во внутренний цикл накладывает ограничение на максимальную длину внутренних циклов в последующих итерациях. Очевидно, что количество уменьшений во внутреннем цикле не может превышать количества увеличений во внешнем, поэтому общее число заходов во внутренний цикл не больше m . Сложность вычисления префикс-функции $O(2m)$. При $m \rightarrow \infty$, сложность $O(m)$.

Сложность поиска шаблона оценивается так же, как и префикс-функция, но внешний цикл проходит по другой строке длины n . Поэтому общая сложность алгоритма для первого задания $O(2m + 2n)$. При $m, n \rightarrow \infty$, сложность $O(m+n)$. Сложность проверки сдвига равна $O(2m + 4n)$, так как внешний цикл там вдвое больше. При $m, n \rightarrow \infty$, сложность $O(m+n)$.

Хранение изначальных строк занимает $O(m + n)$ памяти. Для хранения префикс-функции шаблона дополнительно используется $O(m)$ памяти.

Структуры данных.

`class FullString` -класс хранит текст, шаблон и значения префиксной функции

std::string используется для хранения введенных строк. *std::vector<int>* используется для хранения значений префикс-функции.

Функции.

std::vector<int> FullString::KMP_search()— вычисление префикс-функции для строки. Возвращает вектор результата.

void FullString::isCyclShift() – проверяет, является ли *pattern* циклическим сдвигом *text*. Если да, выводит индекс начала *pattern* в *text*, иначе -1.

void FullString::fill_pf() – заполняет массив значений префиксной функции.

FullString::FullString() – конструктор класса *FullString*. Считывает шаблон и текст, а также вызывает функцию *fill_pf*.

Тестирование.

```
qwe
rtyqweqweasdqwe
***KMP Search***
Current symbol: r
Current match:
Current symbol: t
Current match:
Current symbol: y
Current match:
Current symbol: q
Current match: q
Current symbol: w
Current match: qw
Current symbol: e
Current match: qwe
Current symbol: q
Current match: q
Current symbol: w
Current match: qw
Current symbol: e
Current match: qwe
Current symbol: a
Current match:
Current symbol: s
Current match:
Current symbol: d
Current match:
Current symbol: q
Current match: q
Current match:
Current symbol: q
Current match: q
Current symbol: w
Current match: qw
Current symbol: e
Current match: qwe
3, 6, 12
***Cycle Shift Check***
-1
```

Рис. 2. Тестирование КМП

```
qwerty
rtyqwe
***KMP Search***
Current symbol: r
Current match:
Current symbol: t
Current match:
Current symbol: y
Current match:
Current symbol: q
Current match: q
Current symbol: w
Current match: qw
Current symbol: e
Current match: qwe
-1
***Cycle Shift Check***
Current symbol: r
Current match:
Current symbol: t
Current match:
Current symbol: y
Current match:
Current symbol: q
Current match: q
Current symbol: w
Current match: qw
Current symbol: e
Current match: qwe
Current symbol: r
Current match: qwer
Current symbol: t
Current match: qwerty
3
```

Рис. 1. Тестирование функции поиска циклического переноса

Выводы.

В ходе работы был реализован алгоритм Кнута-Морриса-Пратта для поиска подстрок в строке, а также его модификация для проверки циклического сдвига двух строк.

ПРИЛОЖЕНИЕ А ИСХОДНЫЙ КОД ПРОГРАММЫ

```
#include <iostream>

#include <string>

#include <vector>


using std::vector;

using std::string;

using std::cout;

using std::cin;

using std::endl;


class FullString
//класс хранит текст, шаблон и значения префиксной функции
{
private:
    vector<int> pf; //массив значений префикс функции
    string pattern;
    string S;
public:
    FullString();
    vector<int> KMP_search();
    void isCyclShift();
    void fill_pf();
};


FullString::FullString()
{
    getline(cin, pattern);
    getline(cin, S);
    pf.resize(pattern.length());
    fill_pf();
}
```



```

void FullString::fill_pf()
//заполняем массив значений префиксной функции
{
    pf[0] = 0;

    for (int k = 0, i = 1; i < pattern.length(); ++i)
        //заполняем pf
        {
            while (k > 0 && pattern[i] != pattern[k])
                k = pf[k-1];

            if (pattern[i] == pattern[k])
                k++;

            pf[i] = k;
        }
}

vector<int> FullString::KMP_search()
{
    vector<int> res; // массив результата

    for (int k = 0, i = 0; i < S.length(); i++)
    {
        // Если предыдущий суффикс нельзя расширить, нужно попытаться взять суффикс меньшего размера
        while (k > 0 && pattern[k] != S[i])
            k = pf[k-1];

        // Если символы справа от префикса и суффикса совпадают, суффикс расширяется
        if (pattern[k] == S[i])
            k++;

        //Найдено вхождение
    }
}

```

```

        if (k == pattern.length()) {
            res.push_back(i - k + 1);
        }

        cout << "Current symbol: " << S[i] << endl;
        cout << "Current match: ";
        for (int l=0; l < k; l++)
            cout << pattern[l];
        cout << endl;
    }

    if (res.empty()) {
        res.push_back(-1);
    }

    return res;
}

void FullString::isCyclShift()
{
    //Если длины не равны, сразу откат
    if (pattern.length() != S.length())
    {
        cout << -1;
        return;
    }

    for (int k = 0, i = 0; i < pattern.length()*2; i++)
    {
        //j - циклический обход строки
        int j = i % pattern.length();

        // Если предыдущий суффикс нельзя расширить, нужно попытаться взять суффикс меньшего размера

```

```

while (k > 0 && S[k] != pattern[j])

    k = pf[k-1];

// Если символы справа от префикса и суффикса совпадают, суффикс расширяется
if (S[k] == pattern[j])

    k++;

//Найдено вхождение
if (k == pattern.length()) {

    cout << pattern[k-1];

    cout << endl;

    cout << i - k + 1 << endl;

    return;

}

cout << endl << "Current symbol: " << S[j] << endl;

cout << "Current match: ";

for (int l=0; l < k; l++)

    cout << pattern[l];

}

cout << -1 << endl;

}

int main()

{

    FullString str;

    cout << "***KMP Search***" << endl;

    std::vector<int> res = str.KMP_search();

    cout << res[0];

    for (int i = 1; i < res.size(); i++)

        cout << ", " << res[i];

    cout << endl << "***Cycle Shift Check***" << endl;

    str.isCyclShift();

```

```
    return 0;  
}
```